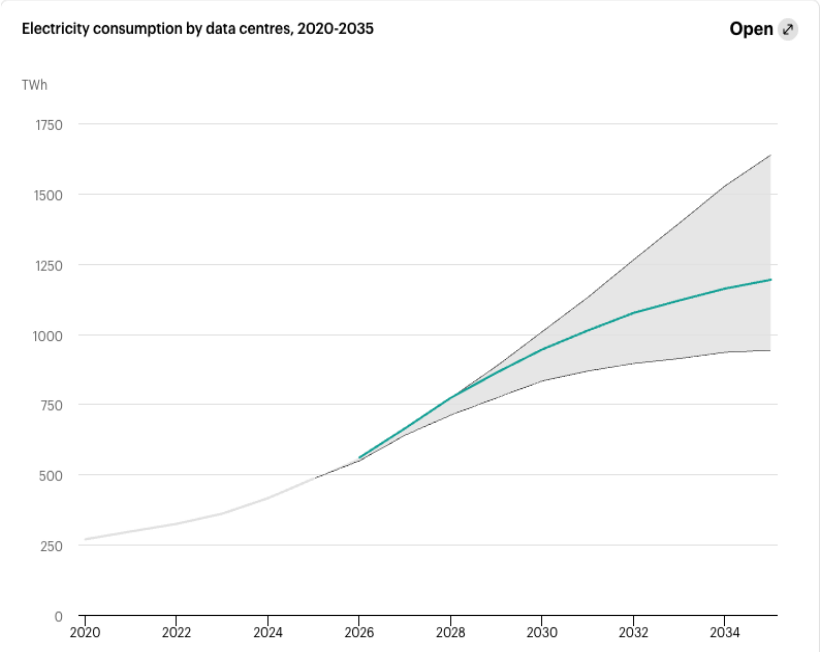
2110582 AI and Applications Midterm Report AY2026S1
6730084521 Chatrphol Ovanonchai

1. ชื่อโครงงานและแนวคิดหลัก

→ การเพิ่มประสิทธิภาพการควบคุมพลังงานด้วยระบบทำความเย็นแบบคาดการณ์ล่วงหน้า (Predictive Cooling Optimization for Data Centers)
→ หัวข้อ : AI for Data Center Energy Efficiency
→ Key Idea : “ถ้าอีก 30 นาทีโหลดเพิ่มขึ้น เราควรปรับระบบทำความเย็นอย่างไรตั้งแต่ตอนนี้ เพื่อให้เครื่องไม่ร้อนเกินและใช้ไฟน้อยที่สุด?”

2. ที่มาและความสำคัญของปัญหา

→ Data Center ใช้พลังงานเยอะขึ้นเรื่อยๆ ซึ่งปัญหาคือพลังงานที่ผลิตขึ้นมา อาจไม่พอกับการใช้ เลยต้องหาวิธีประหยัดพลังงาน โดยการนำ AI เข้ามาช่วยวิเคราะห์และ Optimize การใช้พลังงาน ในด้านการควบคุมอุณหภูมิ และ การควบคุมความเย็น



รูปด้านซ้ายแสดงถึงการใช้พลังงานของตัว Data Center ตั้งแต่ 2020 และคาดการณ์แนวโน้มไปถึง 2035

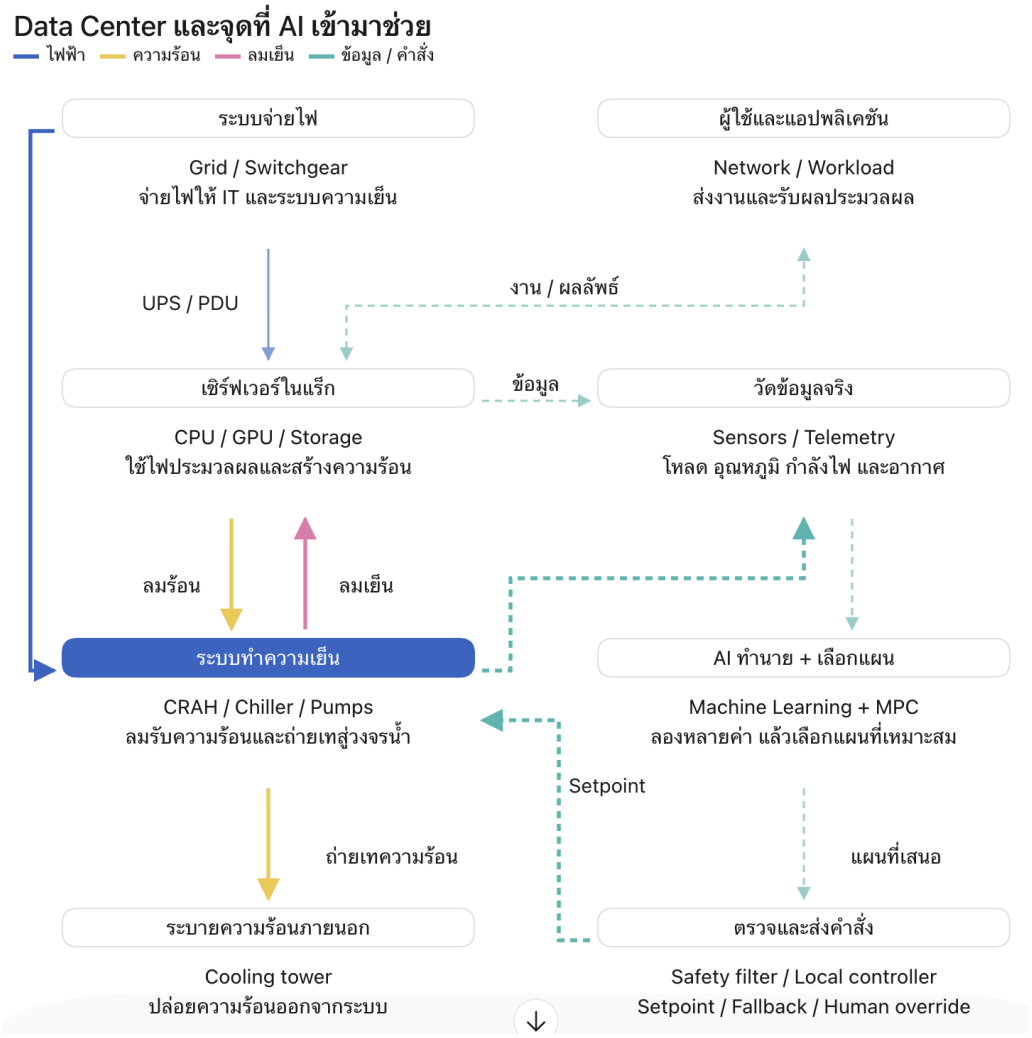
ซึ่งใช้พลังงานสูงขึ้นเรื่อยๆ แต่การผลิตยังคงไม่สูงขึ้นตามไปด้วย เลยต้องหาวิธีการประหยัดพลังงานในตัว Data Center

IEA ฉบับปี 2026 ประเมินว่าการใช้ไฟฟ้าของ Data Center ทั่วโลกอยู่ที่ประมาณ **485 TWh ในปี 2025** และคาดว่าจะเพิ่มเป็นประมาณ **950 TWh ในปี 2030** ตัวเลขปี 2030 เป็นการคาดการณ์ ไม่ใช่การใช้จริงที่เกิดขึ้นแล้ว [Reference]

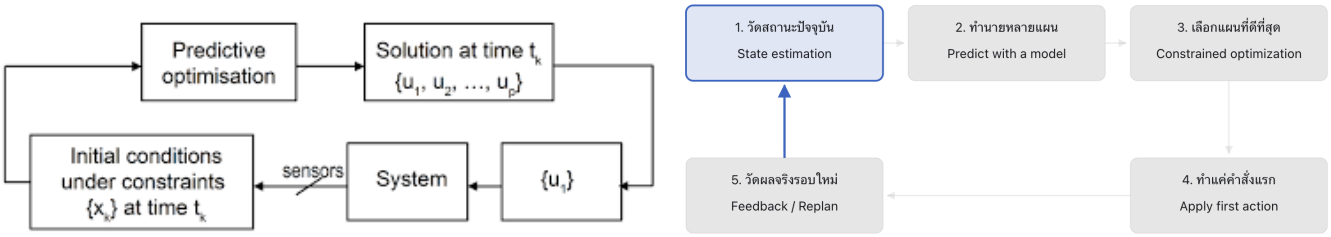
ตัวอย่างสถานการณ์ที่ระบบต้องจัดการ:

สถานการณ์	ปัญหาที่อาจเกิดขึ้น	สิ่งที่ AI ช่วยได้
โหลดเซิร์ฟเวอร์ลดลง แต่ยังรักษาความเย็นระดับเดิม	ใช้ไฟมากเกินจำเป็น	ประเมินว่าลดกำลังทำความเย็นได้เท่าไร
โหลดเพิ่มขึ้นรวดเร็ว	การปรับตามอุณหภูมิที่วัดได้อาจช้า	คาดการณ์ความร้อนและเตรียมระบบล่วงหน้า
บางแร็กร้อนกว่าบริเวณอื่น	ค่าเฉลี่ยอุณหภูมิทั้งห้องซ่อนจุดร้อน	ใช้อุณหภูมิรายจุดประกอบการตัดสินใจ
อากาศภายนอกเปลี่ยน	ประสิทธิภาพอุปกรณ์ทำความเย็นเปลี่ยน	ปรับการควบคุมตามสภาวะแวดล้อม
ปรับแอร์ให้อุ่นขึ้น แต่พัดลมในเซิร์ฟเวอร์ทำงานหนักขึ้น	ไฟฝั่งทำความเย็นลด แต่ไฟรวมอาจไม่ลด	ประเมินพลังงานทั้งระบบ

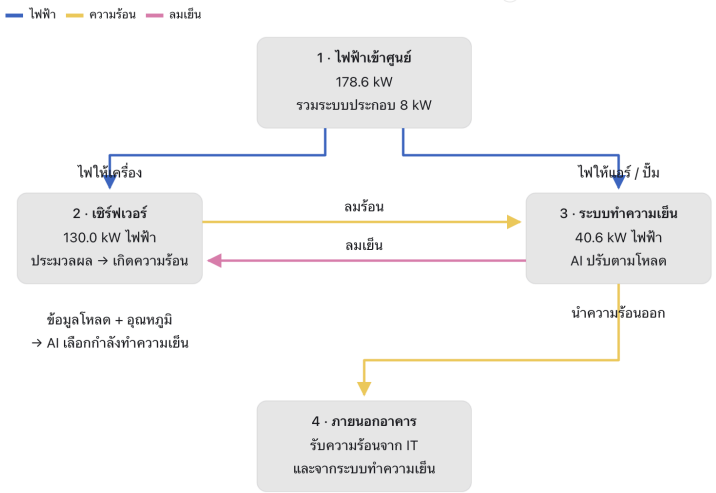
Extra : Intro หลักการการทำงานใน Data Center + Basic Knowledge



Basic Knowledge : Model Predictive Protocol



Basic Knowledge : ระบบการจัดการการใช้ไฟฟ้าใน Data Center



3. วัตถุประสงค์และคำถามของโครงงาน + ตัวชี้วัด

1. เพื่อพัฒนาระบบ**เลือกค่าควบคุมความเย็นด้วย Model Predictive Control**
    a. Target : ตั้งเป้าลดพลังงานทำความเย็น **อย่างน้อย 10%** เทียบกับ Rule-based controller ที่ปรับแต่งแล้ว และพลังงานรวมสุทธิต้องลดลง
    b. Question : ระบบ AI ร่วมกับ MPC สามารถลดพลังงานทำความเย็นได้มากกว่าระบบ Rule-based หรือไม่ เมื่อใช้ workload สภาพอากาศ และสถานะเริ่มต้นเดียวกัน
2. เพื่อพัฒนาโมเดลการคาดการณ์อุณหภูมิ โดยใช้โมเดล AI ประเมินผลของแต่ละทางเลือก
    a. Target : ตั้งเป้าลดพลังงานทำความเย็น **อย่างน้อย 10%** เทียบกับ Rule-based controller ที่ปรับแต่งแล้ว และพลังงานรวมสุทธิต้องลดลง
    b. Question : ระบบที่จะทำนายใหม่ (คาดการณ์อุณหภูมิล่วงหน้า 15 นาที) จะมั่นใจยังไงว่าดีกว่าของเดิม (Persistence Baseline) ยังไง

4. ขอบเขต ผู้ใช้งาน และผู้มีส่วนได้ส่วนเสีย

ประเด็น	รายละเอียด
ข้อมูลนำเข้า	โหลดและกำลังไฟ IT อุณหภูมิระดับโซนหรือจุดวัดที่ simulator รองรับ สภาพอากาศ และค่าควบคุมที่ผ่านมา
เทคนิคที่ใช้	Machine Learning สำหรับพยากรณ์ และ MPC สำหรับเลือกแผนควบคุม
คำสั่งควบคุม	ลด คง หรือเพิ่ม setpoint ภายในขอบเขตที่กำหนด
รอบการตัดสินใจ	เสนอให้คำนวณทุก 15 นาที และมองล่วงหน้า 60 นาที โดยต้องสอดคล้องกับ time step ของ simulator
การประเมินผล	เปรียบเทียบพลังงาน อุณหภูมิ และการทำงานของ Fallback กับ baseline ภายใต้เงื่อนไขเดียวกัน
ผลส่งมอบ	โมเดล AI ตัวควบคุมต้นแบบ Dashboard และรายงานผลทดลอง

ผู้มีส่วนได้ส่วนเสีย	บทบาทหรือผลกระทบ
เจ้าของหรือผู้บริหาร Data Center	ได้ข้อมูลประกอบการประเมินต้นทุนและความคุ้มค่าของระบบ
ทีม IT / SRE	ตรวจผลกระทบต่อประสิทธิภาพและความต่อเนื่องของบริการ
ทีมความมั่นคงปลอดภัย	กำหนดสิทธิ์เข้าถึงข้อมูลและสิทธิ์ส่งคำสั่งควบคุม
ผู้ใช้บริการ Data Center	ได้รับผลกระทบหากการควบคุมทำให้บริการช้าหรือหยุดทำงาน

5. งานวิจัยที่เกี่ยวข้อง

งาน	วิธีและข้อมูล	ผลที่รายงาน / สิ่งที่นำมาใช้	ข้อจำกัดในการนำมาเทียบกับโครงการเรา
Google–DeepMind, 2016 (Reference)	ใช้ข้อมูลเซนเซอร์และ ensemble ของ neural networks ทำนายประสิทธิภาพ อุณหภูมิ และความดัน	รายงานลดพลังงานทำความเย็นได้สูงสุดประมาณ 40%	เป็นระบบของ Google ผลขึ้นกับสถานที่และ baseline
Google–DeepMind, 2018 (Reference)	ควบคุมทำความเย็นอัตโนมัติพร้อมประเมินความไม่แน่นอนและตรวจคำสั่งสองชั้น	รายงานการปรับปรุงประสิทธิภาพพลังงานทำความเย็นเฉลี่ยประมาณ 30%	มีโครงสร้างพื้นฐานและทีมดูแลระดับอุตสาหกรรม
Radovanović และคณะ, 2021 (Reference)	พยากรณ์ความต้องการประมวลผลและความเข้มคาร์บอน แล้วจัดข้อจำกัดกำลังประมวลผลตามเวลา	ระบบจริงของ Google ย้ายงานที่เลื่อนได้ไปช่วงคาร์บอนต่ำ	ลดคาร์บอนไม่ได้แปลว่าลด kWh เสมอ
Naug และคณะ, SustainDC, 2024 (Reference)	สภาพแวดล้อมจำลองสำหรับ workload, cooling และ battery control	ใช้สร้าง benchmark และทดลองอัลกอริทึมได้	เป็นหลักฐานใน simulation ต้องตรวจช่องว่างก่อนใช้จริง
Zhan และคณะ, 2025 (Reference)	Physics-informed offline RL และ graph neural network เรียนรู้จากข้อมูลการทำงาน	ทดลองใน Data Center จริงรวมประมาณ 2,000 ชั่วโมง รายงานประหยัด 14–21% ในระบบทำความเย็นที่ศึกษา	ผลหลักเกี่ยวข้องกับ ACU และตัวชี้วัดพลังงานที่ปรับด้วยโหลดเซิร์ฟเวอร์ ไม่ใช่ไฟรวมทั้งอาคาร

6. แนวทางประยุกต์ใช้ AI หรือกรอบการพัฒนาระบบ

6.1 โมเดลที่เลือก

ใช้ Machine Learning สำหรับการพยากรณ์ (Predictive Model) ร่วมกับ Model Predictive Control: MPC เพื่อจัดการพลังงานของระบบทำความเย็นใน Data Center โดยแบ่งหน้าที่เป็น 2 ส่วน:

- Predictive Model: คาดการณ์อุณหภูมิและการใช้พลังงานในอนาคต ภายใต้ภาระงาน สภาพอากาศ และค่าควบคุมความเย็นแต่ละทางเลือก
- MPC: เปรียบเทียบทางเลือกจากผลคาดการณ์ แล้วเลือกแผนควบคุมที่ใช้พลังงานต่ำ โดยรักษาอุณหภูมิให้อยู่ภายในข้อจำกัดที่กำหนด

6.2 Baseline

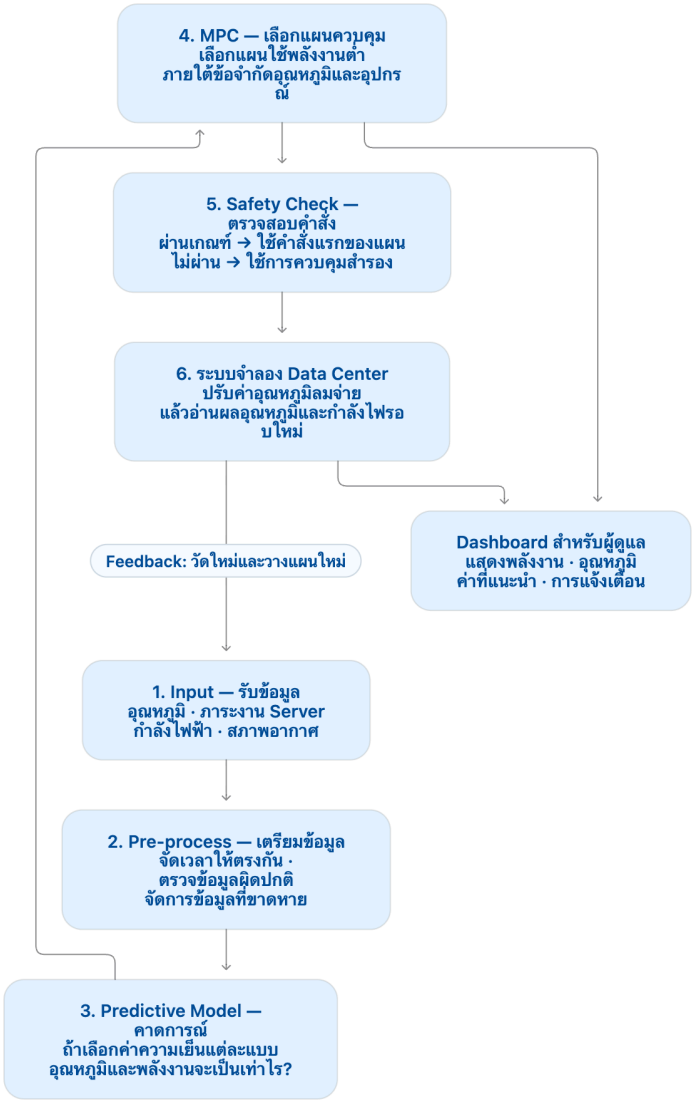
เปรียบเทียบระบบที่เสนอ กับวิธีควบคุมพื้นฐาน 2 แบบ:

- **Fixed Setpoint:** ตั้งค่าอุณหภูมิลมจ่ายของระบบทำความเย็นคงที่
- **Rule-based Control:** ปรับความเย็นตามกฎ เช่น เมื่ออุณหภูมิสูงกว่าเกณฑ์ให้เพิ่มความเย็น

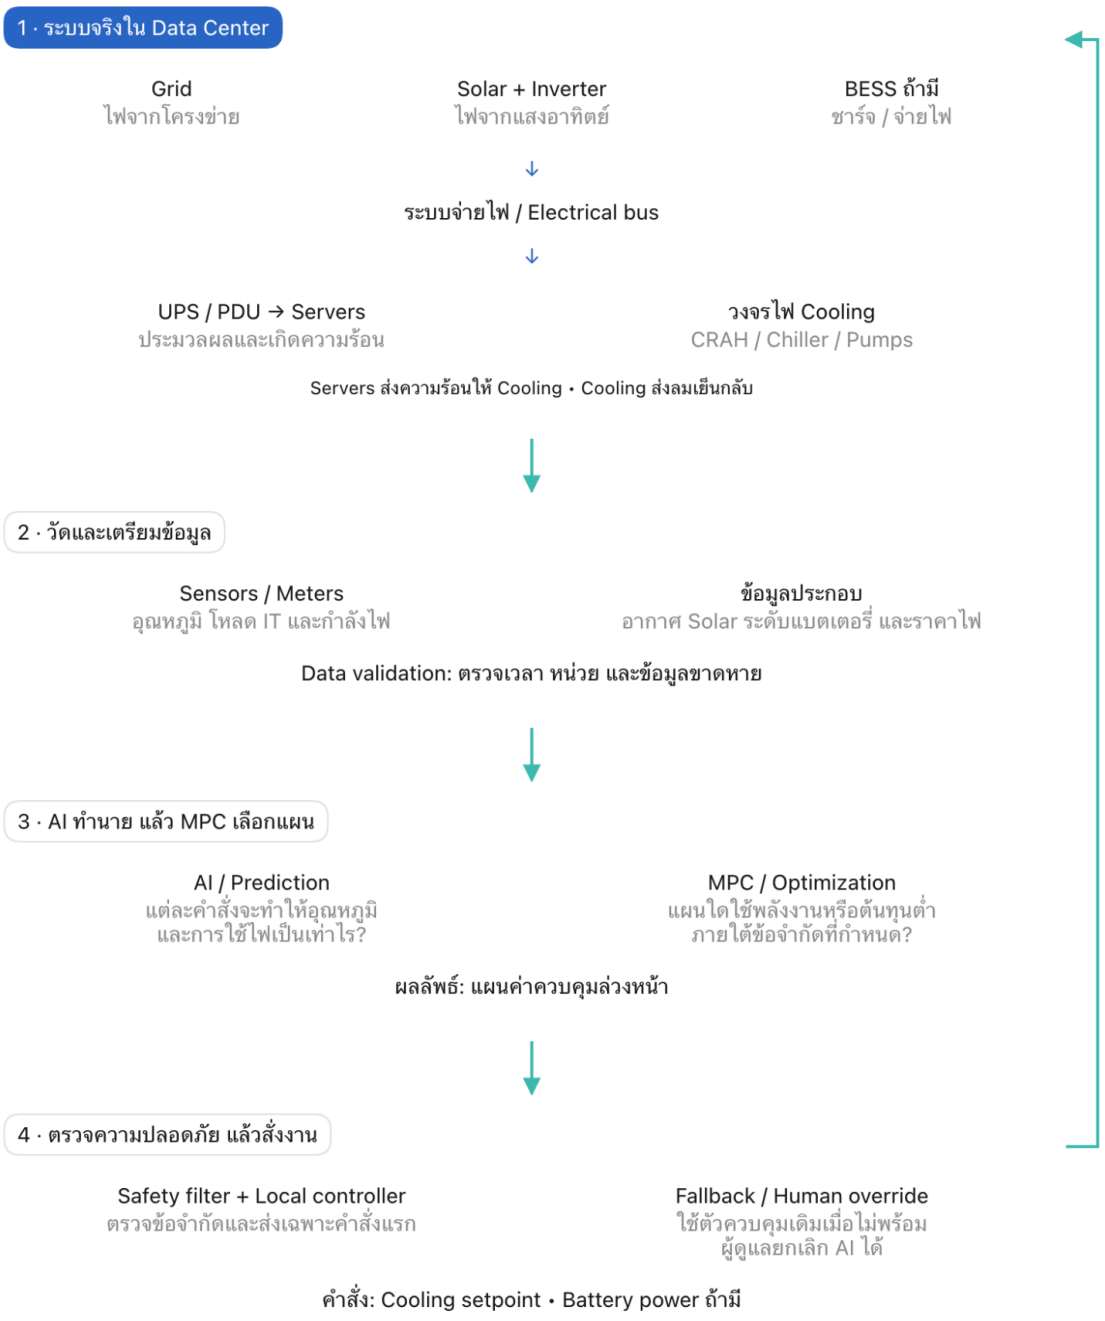
ทดลองภายใต้ภาระงานและสภาพอากาศชุดเดียวกัน โดยเปรียบเทียบ **พลังงานรวม พลังงานระบบทำความเย็น และจำนวนครั้งหรือระยะเวลาที่อุณหภูมิเกินเกณฑ์**

6.3 สถาปัตยกรรมระบบ

1. **Overview : Flow การทำงานโดยรวม**



2. **Overview : Structure การทำงานแต่ละส่วน**



6.4 กระบวนการพัฒนา

ใช้กรอบ CRISP-DM และพัฒนาแบบทำซ้ำ โดยดำเนินการตามขั้นตอน:

กำหนดปัญหาและเป้าหมาย → ศึกษาข้อมูล → เตรียมข้อมูล → พัฒนาโมเดลและ MPC → ประเมินเทียบ Baseline → สาธิตผ่านระบบจำลองและ Dashboard

6.5 Technical Details ใช้โมเดลอะไรบ้าง

แนวทาง	เหมาะกับงานส่วนใด	ข้อพิจารณา
Rule-based/PID	Baseline และระบบสำรอง	ต้องปรับแต่งให้เหมาะสมก่อนเปรียบเทียบ
ML + MPC	ต้นแบบหลัก	อธิบายการเลือกคำสั่งและตรวจข้อจำกัดได้
Reinforcement Learning	งานทดลองเพิ่มเติมใน simulator	ต้องจัดการ reward, การสำรวจ และความต่างระหว่างจำลองกับจริง
Offline RL	ระยะต่อยอดเมื่อมี operational data	คุณภาพและความครอบคลุมของข้อมูลเป็นข้อจำกัดสำคัญ
LLM	สรุปเหตุการณ์และอธิบาย dashboard	คำสั่งควบคุมต้องผ่านตัวควบคุมและกฎที่ตรวจสอบได้

7. Tools ที่ใช้ในส่วนงานต่างๆ

ส่วนงาน	Tools
Simulation	SustainDC
เตรียมข้อมูล	Python, pandas, NumPy
โมเดลพยากรณ์	scikit-learn / XGBoost
Optimization รุ่นแรก	เขียนค้นหา 81 แผนด้วย Python
บันทึกข้อมูลทดลอง	Parquet

Dashboard	Streamlit
เก็บผลและเวอร์ชัน	Git พร้อม configuration และ random seeds

Dataset

แหล่ง	มีอะไร	ข้อจำกัดสำหรับงานเรา
Alibaba Cluster Trace	ข้อมูลการทำงานของคลัสเตอร์จริง เช่น งานและการใช้ทรัพยากร	ใช้สร้างโหลดได้ แต่ไม่ใช่ชุดข้อมูลคำสั่งความเย็นและผลอุณหภูมิครบวงจร
Google Cluster Data	ข้อมูล Workload จากระบบ Borg	เหมาะกับศึกษาหรือจำลองภาระงาน ต้องเสริมส่วนความเย็น
NASA POWER	ข้อมูลอากาศและรังสีดวงอาทิตย์รายชั่วโมงตามพื้นที่	ใช้ต่อยอดสภาพอากาศหรือ Solar ได้ แต่ต้องจัดรูปแบบให้เข้ากับระบบ

8. ตัวชี้วัดและการพิสูจน์ผล

8.1 Measurement ทั้งหมด

มิติ	ตัวชี้วัด	เป้าหมายต้นแบบเบื้องต้น
ความแม่นยำอุณหภูมิ	MAE แยกตามระยะพยากรณ์	ที่ 15 นาที ⩽ 1°C
ความแม่นยำกำลังไฟ	NRMSE โดยระบุตัวหารชัดเจน	⩽ 10% ของกำลังไฟเฉลี่ยชุดทดสอบ
พลังงานทำความเย็น	kWh เทียบ baseline	ลด ⩾ 10%
พลังงานรวม	kWh รวม overhead ของ AI	ต้องลดลง

ความปลอดภัย	จำนวน/ระยะเวลา/ขนาดการเกินเกณฑ์	ไม่พบการเกินเกณฑ์ในชุดทดสอบที่กำหนด
การให้บริการ	ปริมาณงานที่สำเร็จ	เท่ากับ baseline ในการทดลองหลัก
เวลาตัดสินใจ	เวลาคำนวณต่อรอบ	< 10 วินาทีบนเครื่องที่ระบุ
ความทนทาน	การทำงานของ fallback	ผ่านทุก fault scenario ที่กำหนดไว้

8.2 Fixed Variable

ให้ทุกตัวควบคุมใช้:

- workload เดียวกัน
- สภาพอากาศเดียวกัน
- อุปกรณ์และข้อจำกัดเดียวกัน
- สถานะเริ่มต้นเดียวกัน
- ระยะทดลองและช่วง warm-up เดียวกัน

ต้องใช้ simulator หรือ plant model เป็นผู้ตัดสินผล ไม่ให้โมเดลที่ AI ใช้พยากรณ์ประเมินผลงานของตนเองเพียงตัวเดียว และควรทดสอบกรณีที่พารามิเตอร์ของ plant ต่างจากตอนฝึกด้วย

เมื่อมีสถานที่จริง การเปรียบเทียบก่อนและหลังอย่างเดียวอาจปะปนกับผลของอากาศหรือโหลด จึงควรออกแบบช่วงทดลองที่จับคู่กัน หรือสลับตัวควบคุมตามแผนที่วิศวกรอนุมัติ พร้อมเผื่อเวลาระบบปรับตัว

8.3 Baseline ในการเปรียบเทียบ

เสนอ 3 แบบหลัก:

1. ค่าควบคุมคงที่: ใช้แสดงผลของการปรับตามสถานการณ์
2. Rule-based/PID ที่ปรับแต่งแล้ว: เป็นคู่เปรียบเทียบหลัก
3. AI + MPC: ระบบที่เสนอ

หากมีเวลา เพิ่ม MPC ที่ใช้แบบจำลองเชิงเส้น เพื่อแยกให้เห็นว่าประโยชน์มาจากการวางแผนล่วงหน้าหรือจากโมเดล AI ที่เรียนรู้ความสัมพันธ์ได้ดีกว่า

8.4 ตัวอย่างผลลัพธ์ที่ต้องการในการใช้พลังงานใน Data Center

รายการ	ก่อนใช้ AI	หลังใช้ AI

IT	1,000 kW	1,000 kW
Cooling	300 kW	255 kW
ส่วนอื่น	200 kW	200 kW
รวม	1,500 kW	1,455 kW
PUE (Power Usage Effectiveness)	1.500	1.455

กรณีนี้ลดไฟ cooling 15% แต่ลดไฟรวม 3%

พลังงานที่ลดได้ในหนึ่งปี: $45 \times 24 \times 365 = 394,200\ kWh/$ปี

หากสมมติค่าไฟ 4 บาท/kWh จะประหยัดขั้นต้นประมาณ 1.58 ล้านบาทต่อปี

9. จริยธรรม ความเป็นส่วนตัว ความปลอดภัย และ Responsible AI

ความเสี่ยง	มาตรการที่เสนอ
AI ประเมินอุณหภูมิต่ำกว่าความจริง	ใช้ safety margin ตรวจค่าจริงต่อเนื่อง และคง interlock เดิม
ข้อมูลขาดหายหรือโมเดลไม่มั่นใจ	หยุดคำแนะนำและคืนการควบคุมให้ระบบเดิม
คำสั่งเปลี่ยนเร็วเกินไป	จำกัดอัตราการเปลี่ยนและระยะเวลาขั้นต่ำระหว่างคำสั่ง
ข้อมูลครอบคลุมเฉพาะสภาวะปกติ	ทดสอบแยกตามโหลด อากาศ และเหตุผิดปกติ
ข้อมูลเผยรูปแบบการใช้งานของลูกค้า	เก็บเฉพาะ telemetry ที่จำเป็นและใช้รหัสแทนข้อมูลระบุตัว
มีการส่งคำสั่งโดยไม่มีสิทธิ์	แยกสิทธิ์อ่าน/เขียน จำกัดจุดควบคุม และบันทึก audit log

ผู้ดูแลไม่เข้าใจเหตุผล	แสดงทางเลือกที่เปรียบเทียบ พลังงานคาดการณ์ และข้อจำกัดที่ผ่าน
ผลประหยัดถูกกล่าวเกินจริง	แยกผลจำลอง ผลสถานที่จริง เป้าหมาย และสมมติฐาน
ใช้ข้อมูลหรือโค้ดภายนอกผิดเงื่อนไข	ตรวจใบอนุญาตและให้เครดิตแหล่งข้อมูล

10. แผนดำเนินงาน ผลลัพธ์ และการต่อยอด

